

ЦИФРОВЫЕ ТЕХНОЛОГИИ ДЛЯ ПЕРВИЧНОЙ ДИАГНОСТИКЕ РАЗНЫХ МЕДИЦИНСКИХ ЗАБОЛЕВАНИЙ

Яхшибоев Рустам Эркинбой угли¹

Сиддиков Бобурбек Норпулат угли²

Ташкентский университет информационных технологии имени

Мухаммада ал-Хоразмий,

Tashkent, Uzbekistan^{1,2}

e-mail: yaxshiboyevrustam@gmail.com

Аннотация – В данной статье рассмотрено цифровые технологии в диагностике медицинских заболеваний. Сделано анализ использование цифровых технологий в медицине.

Ключивые слова – цифровые технологии, диагностика, лечение заболеваний, медицина, медицинские заболевания.

Abstract – This article discusses digital technologies in the diagnosis of medical diseases. An analysis was made of the use of digital technologies in medicine.

Keywords – digital technologies, diagnostics, treatment of diseases, medicine, medical diseases.

Annotatsiya - Ushbu maqolada tibbiy kasalliklar diagnostikasida raqamli texnologiyalar muhokama qilinadi. Tibbiyotda raqamli texnologiyalardan foydalanish tahlil qilindi.

Kalit so'zlar - raqamli texnologiyalar, diagnostika, kasalliklarni davolash, tibbiyot, tibbiy kasalliklar.

I. ВВЕДЕНИЕ

В настоящее время развития искусственного интеллекта во всех странах мира развивается тщательно и быстро. Связи развития искусственного интеллекта Президент Республики Узбекистана Ш.Мирзиёев дал постановление «О мерах по созданию условий для ускоренного внедрения технологий

искусственного интеллекта», это постановление в соответствии со стратегией «Цифровой Узбекистан – 2030» [1].

В сфере медицины можно широко использовать цифровых технологий при диагностике, лечении разных болезней и разных степенях. С помощью цифровых технологий можно облегчить работу докторов, уменьшается фактор человека, уменьшает время исследований и повышает результативность.

В течении короткой времени доктор может принять решению о диагнозе. С помощью цифровых технологий можно переодолеть спорных моментов. Цифровых технологиях используется искусственный интеллект, нейронные сети, машинная обучения и современные языки программирование Python [2].

Искусственный интеллект — это свойство интеллектуальных систем выполнять творческие функции, которые традиционно считаются прерогативой человека, на сегодняшний день наука и технология позволяет создание интеллектуальных машин, виртуальных помощников, особенно интеллектуальных компьютерных программ [2].

Нейронная сеть — математическая модель, а также её программное или аппаратное воплощение, построенная по принципу организации и функционирования биологических нейронных сетей — сетей нервных клеток живого организма [2].

Машинное обучение — класс методов искусственного интеллекта, характерной чертой которых является не прямое решение задач, а обучение за счёт применения решений множества сходных задач. Для построения таких методов используются средства математической статистики, численных методов,

математического анализа, методов оптимизации, теории вероятностей, теории графов, различные техники работы с данными в цифровой форме.

II. ОСНОВНАЯ ЧАСТЬ

В цифровом технологии было разработано разные диагностические системы, использовано разные технологии искусственного интеллекта. Сделано

анализ методов, алгоритмов, математической модели и результатов несколько диссертации, авторефераты, статьи и тезисы.

Первом научном работе [3,9] было использовано сверточные нейронные сети, с помощью сверточной нейронной сети можно определить огромное разнообразие неврологических заболеваний, а также можно объективно относиться сложности диагноза и процесс лечения.

Диагностика проводится с помощью инструментальных диагностических систем. С помощью инструментальных диагностических систем можно производить большое количество изображений и данные, в следующем шаге можно проводить анализ вручную. Основная задача компьютерных систем является обработка изображений и автоматическое обнаруживание отклонений от нормы.

Инструментальные диагностические системы – это компьютерная и магнитно-резонансная томография (МРТ), электроэнцефалография, электронейромиография и т.д.

Инструментальные диагностические системы строятся с помощью искусственных нейронных сетей. Разработано много реализаций нейронных сетей. Для решения относительно простых задач используются однослойные нейронные сети. В таких сетях входные сигналы попадают на входы искусственных нейронов слоя, каждый из которых обрабатывает поступившие к нему сигналы и выдает результат. Совокупность этих результатов является выходом однослойной сети.

Сверточная нейронная сеть (convolutional neural network, CNN) – это специальная архитектура искусственных нейронных сетей. Основателем был Ян Лекун в 1988 году и нацелена на эффективное распознавание образов и входит в состав технологий глубокого обучения.




Рис 1. Архитектура сверточного нейронной сети

Преимущества свёрточной нейронной сети:

- Лучший алгоритм по распознаванию и по классификацию изображений
- меньше количество настраиваемых весов
- удобное распараллеливание вычислений
- Относительная устойчивость к повороту и сдвигу распознаваемого изображения
- Обучение при помощи классического метода обратного распространения ошибки

Недостатки сверточного нейронного сети:

- слишком много варьируемых параметров сети
- для какой задачи и вычислительной мощности какие нужны настройки
- функция по уменьшению размерности (выбор максимума, среднего и т. п.),
- передаточная функция нейронов,
- наличие и параметры выходной полно связной нейросети на выходе свёрточной

Каскады таких сетей образуют многослойные сети. В настоящее время для распознавания изображений чаще всего применяются сверточные нейронные сети (convolutional neural networks). Это многослойные сети, в которых чередуются слои свертки, фильтрующие входные сигналы, и слои пулинга или объединения, реализующие сокращение размерности.

Так, первый слой свертки последовательно, один за другим, обрабатывает все фрагменты исходного изображения величиной, например, 3x3 пикселя и

«свертывает» эти фрагменты, формируя результирующий признак, который воспринимается функцией активации, имитирующей реакцию нейрона на поступивший сигнал.

Слой пулинга анализирует фрагменты данных из предыдущего слоя размером обычно 2x2 и передает на следующий слой среднее, максимальное или по-другому вычисленное значение. Параметры свертки настраиваются в процессе машинного обучения (тренировки) нейронной сети [3,10,12].

Втором научном работе [4] Разработан метод сегментации по группам объектов, который характеризуется созданием нового порога для сегментации объектов с использованием комбинации порогового значения Оцу и нечеткой кластеризации, что позволяет значительно увеличить скорость и улучшить точность сегментации и классификации объектов на 2-3% по сравнению с современными методами медицинской сегментации (2016-2019 гг.).

Разработан метод определения параметров (порогового значения), которые важны для автоматической сегментации с использованием дискретного вейвлет-преобразования, что позволяет повысить точность сегментации и обнаружения границ объектов интереса (легких) на 1-2% по сравнению с современными методами определения границ легких на медицинских снимках CXR.

Разработаны вычислительная методика и алгоритмическое обеспечение обработки и анализа изображений CXR и КТ на основе усовершенствованного алгоритма CPNN и модифицированного алгоритма шиарлет-преобразования (FFST) для определения границ легких и распознавания патологий на рентгенограммах грудной клетки, включая обнаружение опухолей на изображениях КТ, которые позволяют повысить точность диагностики. Средняя точность распознавания объектов (патологий) на исследуемых базах данных достигает 96 %.

Третьем научном работе [5,15]

1. Разработаны методы анализа обучающих выборок, позволяющие повысить качество нейросетевых моделей:

а) метод выявления аномальных наблюдений с использованием ИНС, основанный на методе анализа удаленных остатков, отличающийся тем, что вместо регрессионных моделей используются нейросетевые;

б) метод вычисления информативности входных параметров посредством анализа нейросетевой модели, отличающийся способом рандомизации входных параметров.

Данные методы показали свою эффективность в условиях ограниченных объемов выборок со сложными корреляционными связями и дискретными входными параметрами, что позволило повысить качество создаваемых нейросетевых моделей в указанных условиях.

2. Разработан метод настройки чувствительности алгоритмов обучения ИНС к ошибкам первого и второго рода, который отличается тем, что параметрический модифицируется вид функции потерь обучения нейронной сети, позволяя варьировать уровень чувствительности и специфичности нейросетевой модели. Это позволяет определять критерии оптимизации обучения ИНС с учетом требований к соответствующим характеристикам нейросетевой диагностической модели.

3. Разработаны два метода, позволяющие повысить точность прогнозирования развития процессов во времени с применением нейросетевых моделей: метод экспертной коррекции и метод скользящего окна. Данные методы эффективны при прогнозировании процессов со сложными корреляционными связями между входными параметрами.

4. Спроектирована и разработана нейросетевая система, предназначенная для диагностики, прогнозирования и построения рекомендаций по лечению и профилактике заболеваний ССС человека. С помощью разработанной системы проведено тестирование предложенных методов и показана их эффективность.

III. РЕЗУЛЬТАТЫ

В первой научной работе было использована свёрточная нейронная сеть. Нейронная сеть была направлена на неврологических заболеваниях. Точность

диагноза была до использования свёрточной нейронной сети 51,60 %. После применение свёрточной нейронной сети точность диагноза составило 97 %.

Во второй научной работе тоже была использована свёрточная нейронная сеть, но применение методов было разным. Применялись методы CNN V-net и CNN U-net.

V-Net показан (Рис2). Левая часть сети состоит из пути сжатия, в то время как правая часть распаковывает сигнал до тех пор, пока не будет достигнут его исходный размер.

Левая часть сети разделена на разные этапы, которые работают с разными разрешениями. Каждый этап включает от одного до трех свёрточных слоев.

На каждом этапе изучается остаточная функция. Входные данные каждого этапа используются в свёрточных слоях и обрабатываются через нелинейности и добавляются к выходу последнего свёрточного слоя этого этапа, чтобы обеспечить возможность обучения остаточной функции. Эта архитектура обеспечивает конвергенцию по сравнению с не вязочной обучающей сетью, такой как U-Net.

В свертках, выполняемых на каждом этапе, используются объемные ядра размером $5 \times 5 \times 5$ вокселей. (Воксель представляет значение на регулярной сетке в 3D-пространстве. Термин воксель обычно используется в 3D во многих 3D-пространствах так же, как вокселизация в облаке точек.)

Вдоль пути сжатия разрешение уменьшается за счет свертки с широкими ядрами вокселей $2 \times 2 \times 2$, применяемыми с шагом 2. Таким образом, размер результирующих карт объектов уменьшается вдвое, с той же целью, что и объединение слоев. И количество каналов функций удваивается на каждом этапе пути сжатия V-Net.

Замена операций объединения на сверточные помогает иметь меньший объем памяти во время обучения из-за того, что для обратного распространения не требуются коммутаторы, отображающие выход слоев объединения обратно на их входы.

Понижающая дискретизация помогает увеличить восприимчивое поле.

PReLU используется в качестве функции активации нелинейности.

Право

Сеть извлекает функции и расширяет пространственную поддержку карт объектов с более низким разрешением, чтобы собрать и собрать необходимую информацию для вывода двухканальной объемной сегментации.

Свертка для понижающей дискретизации (слева), Деконволюция для повышающей дискретизации (справа)

На каждом этапе используется операция деконволюции для увеличения размера входных данных, за которой следует от одного до трех свёрточных слоев, включающих половину числа ядер $5 \times 5 \times 5$, используемых в предыдущем слое.

Изучается остаточная функция, аналогичная левой части сети.

Эти два объекта вычисляются самым последним свёрточным слоем, имеют размер ядра $1 \times 1 \times 1$ и выдают выходные данные того же размера, что и входной объем.

Эти две карты выходных признаков являются вероятностными сегментами областей переднего плана и фона путем применения вокселей soft-max.

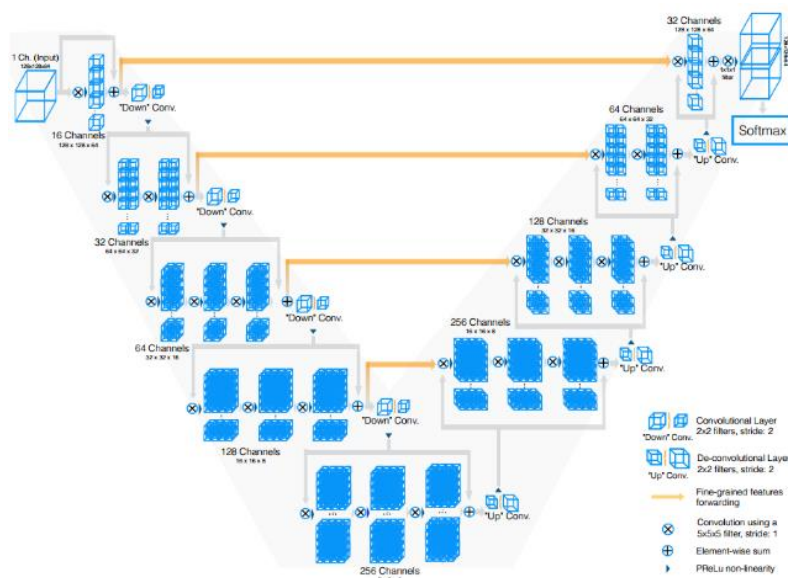


Рис2. Метод CNN V-net

U-Net — это свёрточная нейронная сеть, которая была создана в 2015 году для сегментации биомедицинских изображений в отделении Computer Science Фрайбургского университета. Архитектура сети представляет собой полносвязную свёрточную сеть, модифицированную так, чтобы она могла работать с меньшим количеством примеров (обучающих образов) и делала более точную сегментацию [8,15].

Архитектура сети содержит свёрточную (слева) и разверточную части (справа), поэтому архитектура похожа на букву U, что и отражено в названии. На каждом шаге количество каналов признаков удваивается [8,16].

Свёрточная часть похожа на обычную свёрточную сеть, она содержит два подряд свёрточных слоев 3×3 , после которых идет слой ReLU и пулинг с функцией максимума 2×2 с шагом 2.

Каждый шаг разверточной части содержит слой, обратный пулингу, который расширяет карту признаков, после которого следует свертка 2×2 , которая уменьшает количество каналов признаков [17,7].

После идет конкатенация со соответствующим образом обрезанной картой признаков из сжимающей части и две свертки 3×3 , после каждой из которой идет ReLU [17,7].

Обрезка нужна из-за того, что мы теряем пограничные пиксели в каждой свёртке. На последнем слое свертка 1×1 используется для приведения каждого 64-компонентного вектора признаков до требуемого количества классов.

Всего сеть имеет 23 свёрточных слоев. Две статьи авторов сети имеют более 1600 и 1000 цитирований на май 2018 года.

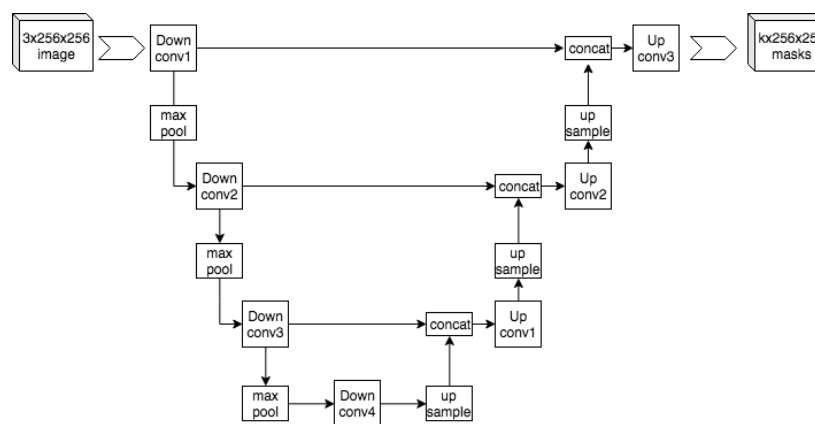


Рис3. Метод CNN U-net

IV. ЗАКЛЮЧЕНИЕ

Анализ ряда научных исследований свидетельствует о том, что исследовались различные архитектуры и модели искусственных нейронных сетей.

В первом научном исследовании, использовано архитектура CNN, наблюдалась низкая производительность модели в процессе обучения данных. Если модель работает медленно, прогноз заболевания тоже будет медленным. Это пустая трата времени. [3,9]

Во втором научном исследовании процесс обучения результатов анализа полученных при обучении моделей V-net и U-net архитектуры CNN, также несколько медленный. Но хорошие результаты были получены в двух научных исследованиях. [4,10]

Было бы хорошо, если для прогнозирования заболеваний использовалась нейронная сеть DEEP. Это связано с тем, что полученные результаты анализа и эффективность обучения данных показали несколько более высокие результаты.

СПИСОК ИСПОЛЬЗОВАННЫХ ЛИТЕРАТУР

1. Постановление Президента Республики Узбекистан, от 17.02.2021 г. № ПП-4996. lex.uz/docs/5297051
2. Предварительная прогнозирование медицинских заболеваний с помощью нейронных сетей. Яхшибоева Д.Э. Material of International students conference.2021

3. Цифровые технологии в диагностике и лечении неврологических заболеваний. Н.В.Петухова, М.П.Фархадов, М.В.Замерград, С.П.Грачев. 2022.
4. Разработка и исследование алгоритмов сегментации и распознавания объектов на медицинских изображениях на основе шпираль-преобразования и нейронных сетей. Хамад Ю.А. 2020.
5. Методы повышения эффективности нейросетевых рекомендательных систем в условиях ограниченных объемов выборок со сложными корреляционными связями (на примере диагностики и прогнозирования сердечно-сосудистых заболеваний человека). Черепанов Ф.М. 2019.
6. V-Net — Volumetric Convolution (Biomedical Image Segmentation).Sik-Ho Tsang. 2019.
7. Andersson J, Ahlström H, Kullberg J (September 2019). "Separation of water and fat signal in whole-body gradient echo scans using convolutional neural networks"
8. Long, J.; Shelhamer, E. & Darrell, T. (2014), Fully convolutional networks for semantic segmentation
9. M. B. Boltaevich, N. R. H. ogli, G. N. S. qizi and M. S. S. ogli, "Estimation affects of formats and resizing process to the accuracy of convolutional neural network," 2019 International Conference on Information Science and Communications Technologies (ICISCT), 2019, pp. 1-5, doi: 10.1109/ICISCT47635.2019.9011858.
10. Muminov, B., et al. "Localization and Classification of Myocardial Infarction Based on Artificial Neural Network,(2020) 2020 Information Communication Technologies Conference." (2020): 245-249.
11. R. Yakhshibaev, B. Turaev, K. Jamolov, N. Atadjanova, E. Kim and N. Sayfullaeva, "Development of a mathematical model for balancing the level and device for remote monitoring of groundwater parameters," 2021 International Conference on Information Science and Communications Technologies (ICISCT), 2021, pp. 1-4, doi: 10.1109/ICISCT52966.2021.9670022.

12. Yaxshiboyev, Rustam, and Dilbar Yaxshiboyeva. "ANALYSIS OF ALGORITHMS FOR PREDICTION AND PRELIMINARY DIAGNOSTICS OF GASTROENTEROLOGICAL DISEASES." CENTRAL ASIAN JOURNAL OF EDUCATION AND COMPUTER SCIENCES (CAJECS) 1.2 (2022): 49-56.
13. Ermetov E. Y. Yaxshiboyev RE Gastroenterologik kasalliklarni KNN algoritmi asosida bashoratlovchi dastur //O ‘zbekiston Respublikasi intellektual mulk agentligi. Elektron hisoblash mashinalari uchun yaratilgan dasturning rasmiy ro‘yxatdan o‘tkazilganligi to‘g‘risidagi guvohnoma.№ DGU. – T. 17014.
14. Ermetov E. Y. Yaxshiboyev RE Gastroenterologik kasalliklarni ANN algoritmi asosida bashoratlovchi dastur //O ‘zbekiston Respublikasi intellektual mulk agentligi. Elektron hisoblash mashinalari uchun yaratilgan dasturning rasmiy ro‘yxatdan o‘tkazilganligi to‘g‘risidagi guvohnoma.№ DGU. – T. 17016.
15. Ermetov E. Y. Yaxshiboyev RE Gastroenterologik kasalliklarni SVM algoritmi asosida bashoratlovchi dastur //O ‘zbekiston Respublikasi intellektual mulk agentligi. Elektron hisoblash mashinalari uchun yaratilgan dasturning rasmiy ro‘yxatdan o‘tkazilganligi to‘g‘risidagi guvohnoma.№ DGU. – T. 17015
16. Yaxshiboyev, R. E., et al. "FORECASTING GROUNDWATER EVAPORATION USING MULTIPLE LINEAR REGRESSION." Galaxy International Interdisciplinary Research Journal 9.12 (2021): 1101-1107.
17. Djumanov, Jamoljon, et al. "Mathematical model and software package for calculating the balance of information flow." 2021 International Conference on Information Science and Communications Technologies (ICISCT). IEEE, 2021.